

动态任务迁移图驱动的 Auto-Research 探索系统

试点结果与全量展望 · Pilot Findings & Outlook

脑医学影像域 · 886 篇子样 · 2026-06-01 · github.com/vveii14/Auto-Research




图 0. 系统总览: 语料 → LLM 抽取(任务/方法节点 + 有向迁移边) → 导航(富节点投影 + 结构空洞) → 探索回流(图生长) → 治理; 底部为「历史回放」评测。

1. 执行摘要

本系统把「自动科研方向发现」建模为时序图上的候选迁移边预测:从带时间戳的论文中抽取任务/方法节点与有向、有符号的「A 是否帮助 B」迁移边,构成一张随探索生长、并反过来导航探索的活体图;再用「历史当标签」的时序回放检验它是否越用越准。本报告给出在脑医学影像 886 篇子样上的端到端试点结果。

核心结论(诚实标注):

- 已显著:图结构导航预测未来研究方向,显著优于「无图直接问 LLM」、共现图、随机(配对检验 CI 不含 0)。这同时证明收益来自图结构、而非 LLM 记忆泄漏。
- 尚未显著:核心卖点「复利」(growing > frozen)方向一致为正、但在 900 篇规模下 CI 仍跨 0,需扩量定论。
- 真实弱点:当前 method→task 边里 78% 是「纯使用」而非「真迁移」;全图真迁移边仅约 23%。已定位主因为抽取 prompt,可修。
- 判断:idea 的基础设施与「图 > 基线」已坐实(可作安全网论文);「复利」待一次有止损线的扩量赌定。

2. 核心 idea 与 workflow

定位:第一个把研究关系图从「静态只读底座」变成「随探索动态生长、并反过来导航探索」的活体结构。对手 Intern-Atlas(静态只读)、Deep Ideation(底图固定)、AC/DC(无关系图)。novelty 在于有向迁移语义 + 活体生长 + 图导航 + 复利,对 method→task 与 task→task 两类边平权。

workflow(8步):

- 定语料范围(可调参数:会议/期刊/年份/规模)
- 无差别读入带时间戳论文
- LLM 抽取:任务/方法节点 + 有向迁移边(含逐字证据)
- 传递推断: $A \rightarrow B, B \rightarrow C \Rightarrow A \rightarrow C$,补稀疏区
- 导航(非随机,核心):富节点投影 + 结构空洞 + 拓扑打分,LLM 仅笼中过滤,输出 top-k 方向
- 探索 + 回流:方向交自动研究,成功/失败均回流为 verified 边,图生长
- 治理:去重 / 冲突消解 / 衰减,防变脏
- 持续接收新论文,图随领域生长

评测(独立注入真值):用 $\leq T$ 年的图预测 $T+1$ 真实出现的迁移边,先打分再回灌,逐年滚动;比较 growing / frozen / 共现图 / 无图 LLM / 随机。历史发表即免费、客观的标签,从而避免循环论证。

3. 试点设置与语料

来源 Semantic Scholar(仅摘要);过滤 fieldsOfStudy=Computer Science + 脑影像/方法关键词;年份 2015 – 2024;全量已下 8,000 篇,试点用其中 886 篇子样(≤ 2020 取 500 篇建图,2021 – 24 各 100 篇作预测目标/回灌)。抽取用 Azure 托管 Opus,embedding 用 all-MiniLM-L6-v2。




图 1. 语料年份分布,2015→2024 稳定增长,适合时序留出;红线为 T0=2020 的建图/预测分界。

4. 构建出的迁移图

886 篇 → 实体消解后 2,907 节点(任务 1,064 / 方法 1,843)、1,748 条抽取边,传递推断再补约 518 条。边以 method→task 为主(1,581),task→task 131,method→method 36。




图 2. 图构成:节点类型(左)与边类型(右,叠加显示抽取 vs 传递推断)。

真实 task→task 迁移边样例(who-helps-whom):

源任务 → 目标任务	证据(节选)
年龄预测(结构 MRI) → 阿尔茨海默诊断	sensitive to deviance from normal aging...
海马分割 → 阿尔茨海默分类	multi-task CNN jointly learning hippocampus...
虚拟连接组推断 → AD 分类	trained on virtual connectomes can be used...
PET 分割 ⇌ 去噪 ⇌ 部分容积校正	segmentation can help in denoising and PVC...

5. 试点结果

5.1 导航准确率(语义匹配,bootstrap 95% CI)

同一时序预测任务上,我方(growing/frozen)在各 k 下稳定优于共现图、无图 LLM 与随机。无图 LLM 几乎与随机持平——说明仅靠 LLM(含其记忆的未来)很弱,提升来自图。




图 3. 各臂 semantic precision@k 与 95% 置信区间(4 个 T0 × 年份汇总)。

臂	P@10	P@20	P@50
growing	0.127	0.093	0.079
frozen	0.091	0.075	0.056
cooccur(共现)	0.027	0.057	0.047
no-graph LLM	0.023	0.016	0.013
random	0.000	0.000	0.001

5.2 复利探针:growing vs frozen

沿起始年 T0 扫描:底盘小、增长占比大时(T0=2017、2019)growing 明显高于 frozen;底盘大、年增量小时(T0=2020)趋于打平——符合「增量需相对底盘足够大才显现复利」的预期,也正是 900 篇子样在晚期 T0 的人为局限。




图 4. growing(图逐年生长)与 frozen(图固定于 T0)随 T0 的对比。

5.3 决定性配对检验

growing – 无图 LLM 在所有 k 下 CI 全部 > 0(显著); growing – frozen 均值恒为正但 CI 仍跨 0(尚不显著)。




图 5. 配对差值与 95% CI; 绿色 = CI 不含 0(显著)。

5.4 边质量审计:真迁移 vs 纯使用

按「真迁移(预训练/表征复用/multi-task/涨点)vs 纯使用(仅把方法用于任务)」分类: method→task 仅 20% 是真迁移、78% 是纯使用; task→task 反而 65% 是真迁移。估算全图真迁移边仅约 23%。




图 6. 边质量审计(每类 40 条抽样)。当前图大半是「方法-任务使用表」,真迁移是少数。

5.5 抽取 prompt 是关键杠杆

全文 vs 摘要 A/B 显示:把 task→task 做厚的主杠杆是抽取 prompt,而非读全文。同样的摘要,改用强化迁移 prompt,task→task 占比即从 8% 升到 32%;全文反而稀释比例(加入更多 method→task)。




图 7. task→task 边占比:通用 prompt vs 强化迁移 prompt vs +全文。

6. 已证明 / 待解决

已证明(显著):

- 图结构导航 > 无图 LLM、> 共现图、>> 随机(配对 CI 不含 0)。
- 收益来自图,而非 LLM 记忆泄漏(无图 LLM 接近随机)。

待解决:

- 复利(growing > frozen)方向一致但未显著——需扩量(更多年份/数据点收紧 CI)。
- 边质量:真迁移仅约 23%,需「区分迁移/使用」的重抽提纯。
- 规模与噪声:900 篇子样、仅摘要、单 embedding,数字偏小且抖。

7. 全景展望与路线

最关键三步(其余为工程放大):

- 提纯重抽:用「区分真迁移 vs 纯使用、两类源平权」的 prompt 重抽,先低成本验证图质量与「图 > 基线」在提纯后是否依然成立。
- 扩量定复利:扩到约 3,000 篇并加多起始年 T0,把 growing - frozen 的 CI 推离 0;读全文进一步加厚真迁移。
- 完全体:本地 72B 抽取(可复现、防泄漏)+ Neo4j/向量索引 + 治理常开 + 多域(脑→视网膜→心脏)+ 接真实 auto-research 闭环 demo。

止损线:扩量后复利仍不显著,则收敛为「结构导航 > 无图 LLM/共现/随机」的弱化版论文(已显著)。

附:实现进度

阶段	内容	状态
P0	取数 + 图骨架	完成(8000 篇)
P1	抽取验证	完成
P2	建图 + 消解 + 推断	完成(886 篇)
P3	图导航	完成
P4 - P6	时序评测 + 置信区间	完成
P7 - P8	全文 A/B + 边质量审计	完成
—	提纯重抽 / 扩量 / 完全体	待进行